

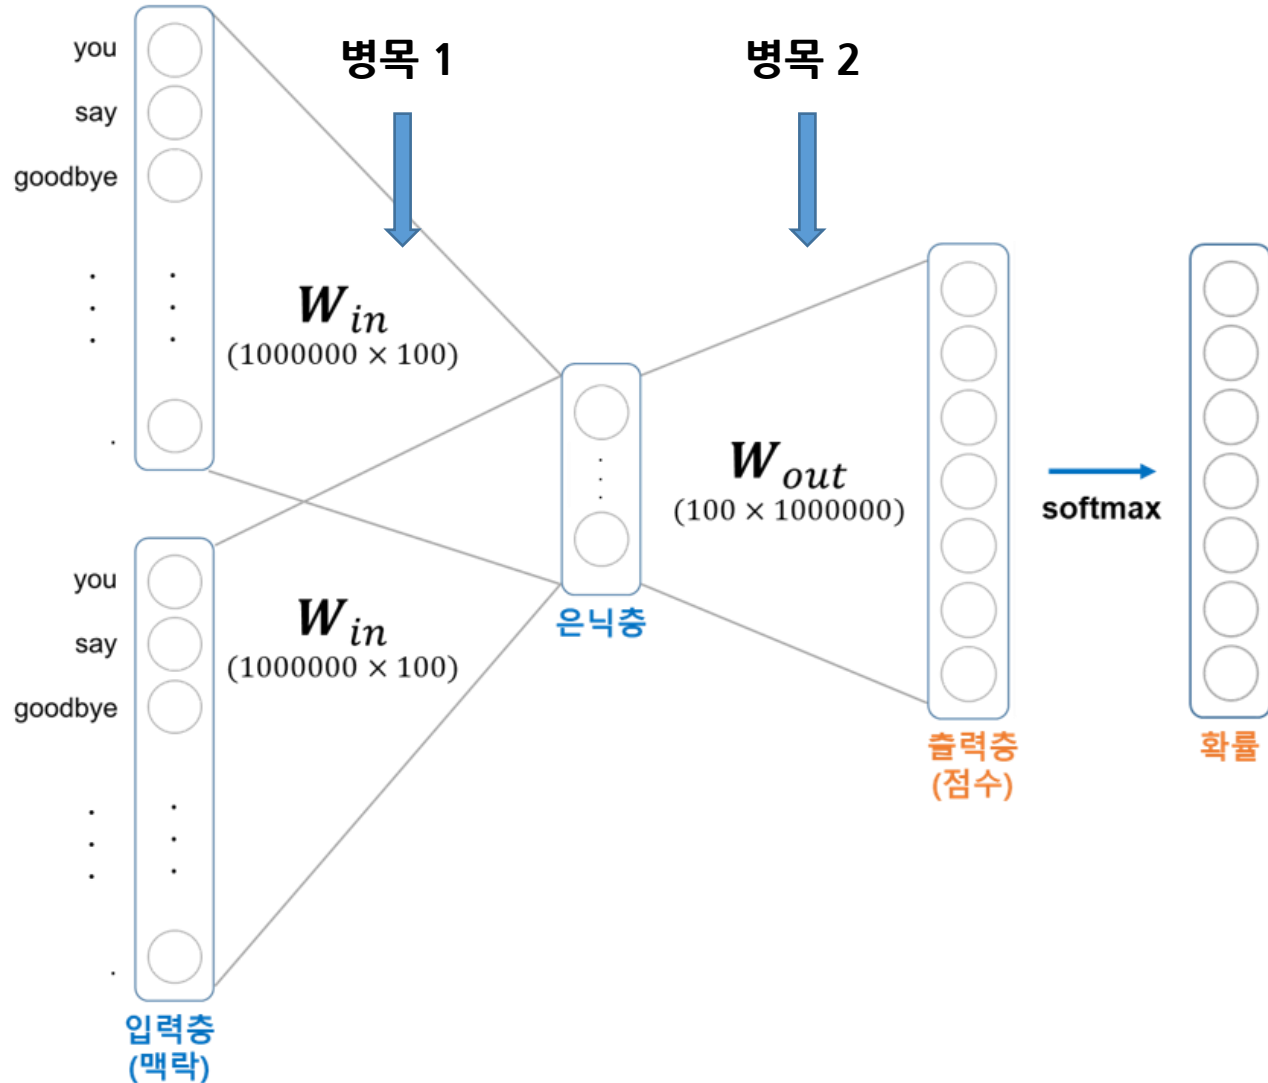
---

## 4장 word2vec 개선

---

## - CBOW 모델

어휘가 100만 개일 때를 가정한 CBOW 모델



병목

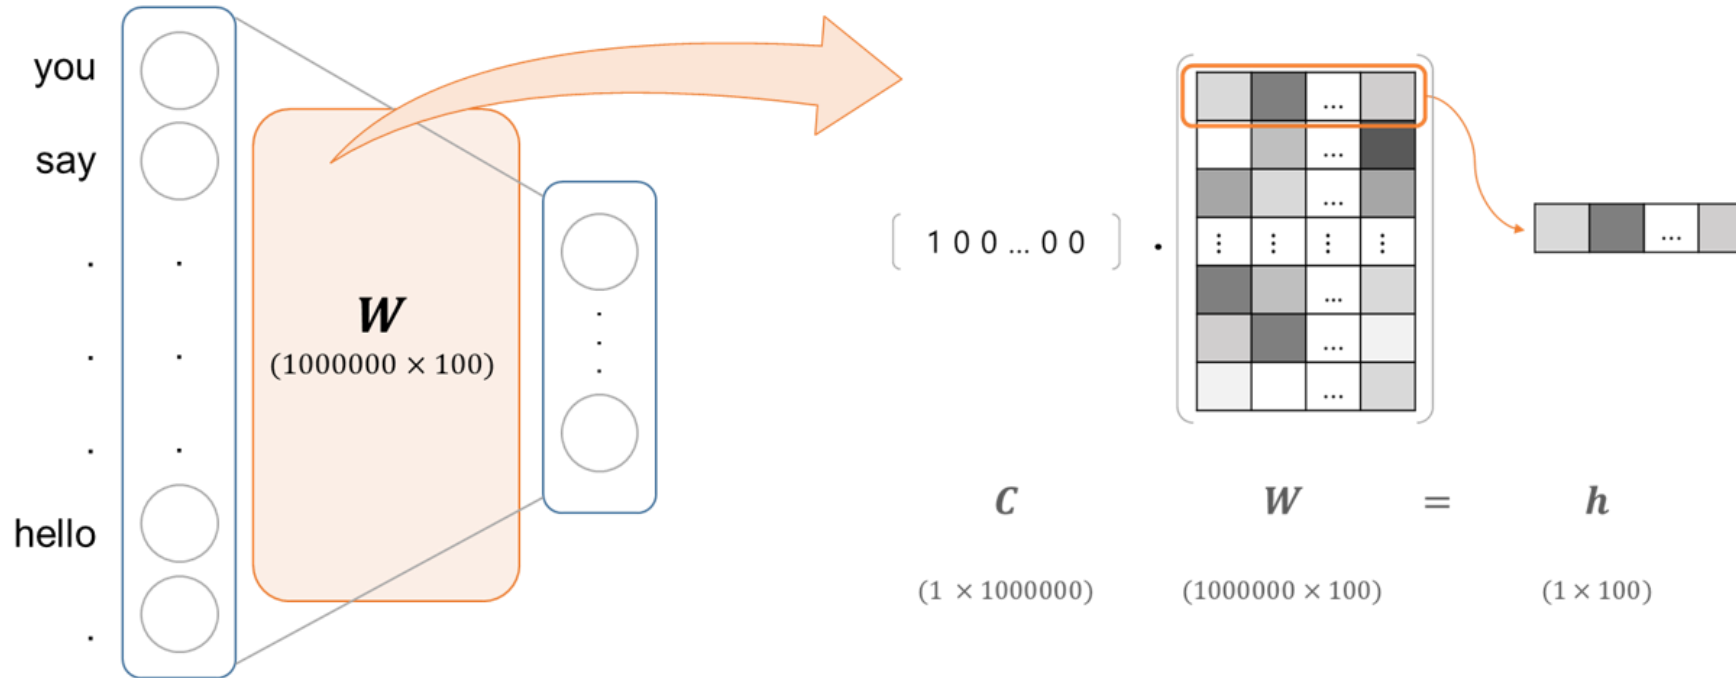
1. 입력층의 원 핫 표현과 가중치 행렬  $W_{in}$ 의 곱 계산
2. 은닉층과 가중치 행렬  $W_{out}$ 의 곱 및 Softmax 계층의 계산

해결 방안

1. Embedding 계층 도입
2. 네거티브 샘플링 사용

## - CBOW 모델 개선

### Embedding 계층 사용



### 결론

원 핫 표현으로서의 변환과 Matmul 계층의 행렬 곱 계산은 필요 없음 => 가중치 행렬의 행을 추출과 동일

Embedding 계층 : 가중치 행렬의 특정 행을 추출하여 반환하는 계층

## - CBOW 모델 개선

### Embedding 계층 구현

#### 임의의 행렬 정의

```
import numpy as np

W = np.arange(21).reshape(7, 3)
W
```

array([[ 0, 1, 2],  
 [ 3, 4, 5],  
 [ 6, 7, 8],  
 [ 9, 10, 11],  
 [12, 13, 14],  
 [15, 16, 17],  
 [18, 19, 20])

#### 행렬 인덱싱

```
# 두 번째 행 가져오기  
# -> index=2에 해당하는 단어 벡터  
W[2]
```

array([6, 7, 8])

#### 여러 행 추출

```
# 가중치 W로 부터 여러행을  
# 한꺼번에 추출하는 예제  
idx = np.array([1, 0, 3, 0])  
W[idx]
```

array([[ 3, 4, 5],  
 [ 0, 1, 2],  
 [ 9, 10, 11],  
 [ 0, 1, 2])

## - CBOW 모델 개선

Embedding 계층 순전파와 역전파

순전파

가중치 W의 특정 행을 추출하는 것

=> 특정 행을 추출해 반환

```
def forward(self, idx):  
    W, = self.params  
    self.idx = idx  
    out = W[idx]  
    return out
```

역전파

출력 층 쪽으로부터 전해진 기울기를 그대로 흘려주는 것

```
def backward(self, dout):  
    dW, = self.grads  
    dW[...] = 0  
    np.add.at(dW, self.idx, dout)  
    return None
```

## Word2vec 개선 - 네거티브 샘플링 기법

## Word2vec 개선 - 네거티브 샘플링 기법

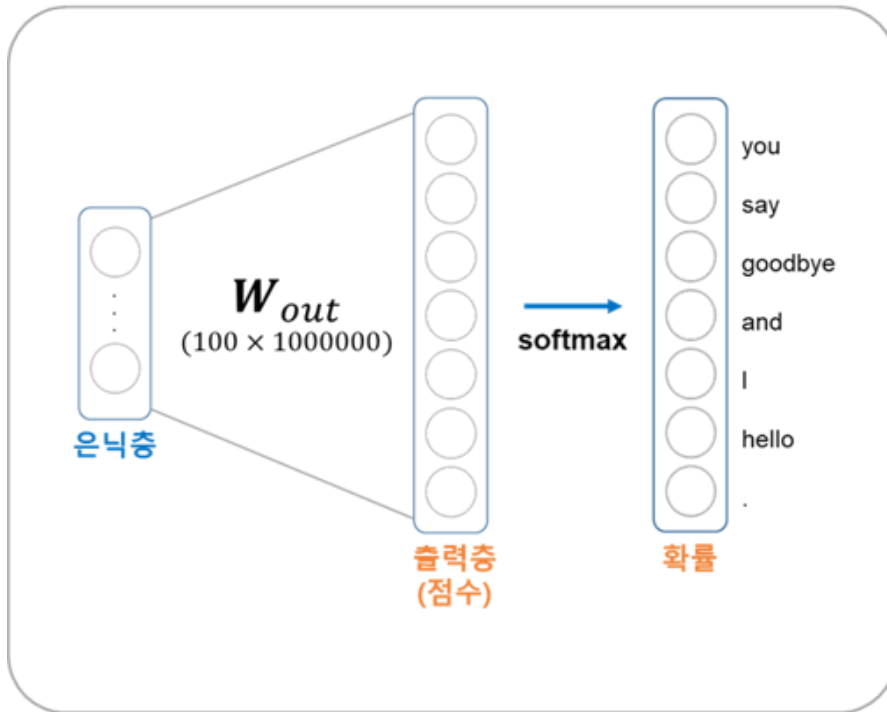


1. 은닉층의 뉴런과 가중치 행렬  $W(\text{out})$ 의 곱
2. Softmax 계층의 계산

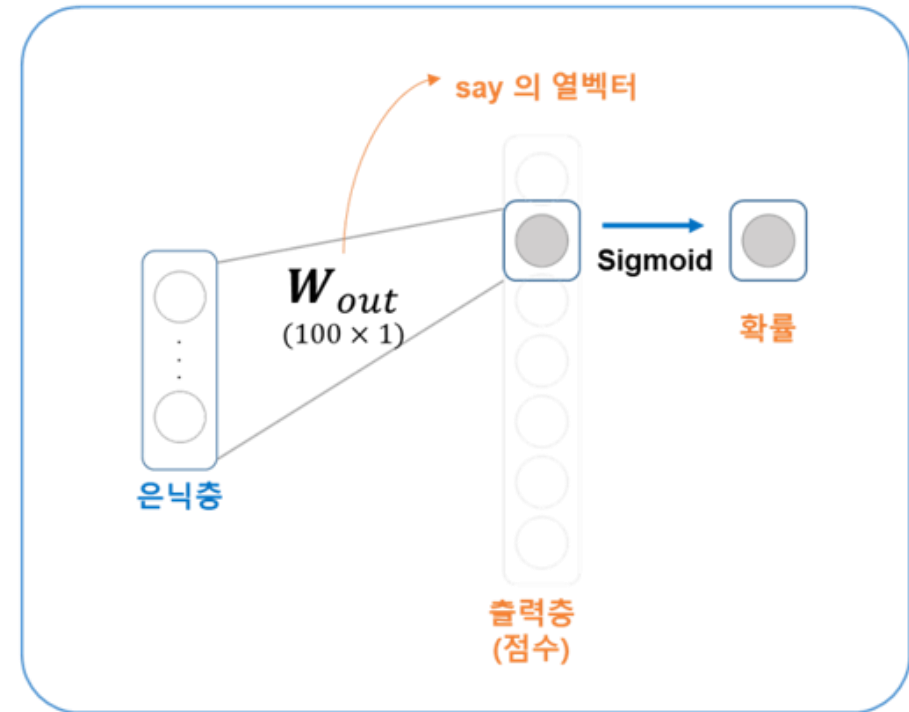
## - CBOW 모델 개선

Word2vec 개선 - 네거티브 샘플링 기법

Multi-class Classification



Binary Classification



다중 분류 -> 이진 분류 문제로 근사

예)

You와 goodbye 입력 시 say 에 대해서만 점수를 출력

## - CBOW 모델 개선

네거티브 샘플링 기법

이진 분류 문제

- 출력 층에 시그모이드 함수 적용 -> 확률로 변환

- 손실 함수로 교차 엔트로피 오차를 사용


$$L = -[t \log y + (1 - t) \log(1 - y)]$$




## - CBOW 모델 개선

네거티브 샘플링 기법

시그모이드 계층 역전파




역전파 과정



## - CBOW 모델 개선

임베딩 계층과 이진 분류 적용



## - CBOW 모델 개선

### 네거티브 샘플링 기법

#### 학습

정답인 단어를 사용해 손실 함수 사용, 정답이 아닌 다른 단어에 대한 확률 값은 어떻게 구할지 잘 학습하지 못함

=> 네거티브 샘플링 사용

예)

입력: you 와 goodbye

출력으로 say를 예측하고, 이외의 단어에는 출력이 0에 가까워야 하기 위해

정답 레이블 이외의 단어 또한 학습에 포함

## - CBOW 모델 개선

### 네거티브 샘플링 기법

#### 학습

정답인 단어를 사용해 손실 함수 사용, 정답이 아닌 다른 단어에 대한 확률 값은 어떻게 구할지 잘 학습하지 못함

=> 네거티브 샘플링 사용

예)

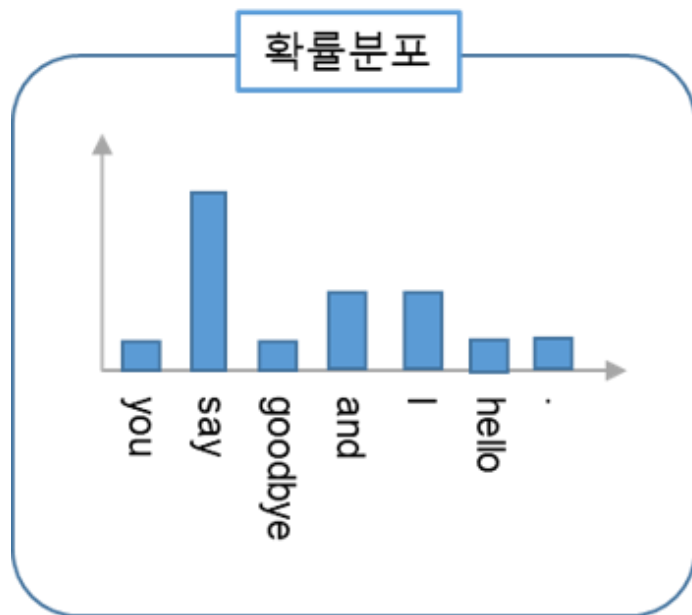
입력: you 와 goodbye

출력으로 say를 예측하고, 이외의 단어에는 출력이 0에 가까워야 하기 위해

정답 레이블 이외의 단어 또한 학습에 포함

## - CBOW 모델 개선

네거티브 샘플링 기법



샘플링

you

say

goodbye

and

|

hello

.

무작위 추출보다 성능이 좋은 방법

=> 확률 분포에 기반해 추출하는 방법

## - CBOW 모델 개선

### 네거티브 샘플링 기법

#### 확률 분포 제공

```
p = [0.7, 0.29, 0.01]  
new_p = np.power(p, 0.75)
```

```
new_p /= np.sum(new_p)  
print(new_p)
```

```
[0.64196878 0.33150408 0.02652714]
```

$$P'(w_i) = \frac{P(w_i)^{0.75}}{\sum_j^n P(w_j)^{0.75}}$$

- 분포에서 희소한 단어가 더 쉽게 샘플링 되도록 하는 방법

## - CBOW 모델 개선

### 네거티브 샘플링 파이썬 구현

```
class NegativeSamplingLoss:
    def __init__(self, W, corpus, power=0.75, sample_size=5):
        self.sample_size = sample_size
        self.sampler = UnigramSampler(corpus, power, sample_size)
        self.loss_layers = [SigmoidWithLoss() for _ in range(sample_size + 1)]
        self.embed_dot_layers = [EmbeddingDot(W) for _ in range(sample_size + 1)]

        self.params, self.grads = [], []
        for layer in self.embed_dot_layers:
            self.params += layer.params
            self.grads += layer.grads

    def forward(self, h, target):
        batch_size = target.shape[0]
        negative_sample = self.sampler.get_negative_sample(target)
```

## - CBOW 모델 개선

### 네거티브 샘플링 순전파

```
def forward(self, h, target):
    batch_size = target.shape[0]
    negative_sample = self.sampler.get_negative_sample(target)

    # 긍정적 예 순전파
    score = self.embed_dot_layers[0].forward(h, target)
    correct_label = np.ones(batch_size, dtype=np.int32)
    loss = self.loss_layers[0].forward(score, correct_label)

    # 부정적 예 순전파
    negative_label = np.zeros(batch_size, dtype=np.int32)
    for i in range(self.sample_size):
        negative_target = negative_sample[:, i] # embed_dot에 해당하는
        score = self.embed_dot_layers[1 + i].forward(h, negative_target)
        loss += self.loss_layers[1 + i].forward(score, negative_label)

    return loss
```

### 네거티브 샘플링 역전파

```
def backward(self, dout=1):
    dh = 0
    for l0, l1 in zip(self.loss_layers, self.embed_dot_layers):
        dscore = l0.backward(dout)
        dh += l1.backward(dscore)

    return dh
```



## - CBOW 모델 개선

### 개선 word2vec 학습

```
class CBOW:
    def __init__(self, vocab_size, hidden_size, window_size, corpus):
        V, H = vocab_size, hidden_size

        # 가중치 초기화
        W_in = 0.01 * np.random.randn(V, H).astype('f')
        W_out = 0.01 * np.random.randn(V, H).astype('f')

        # 레이어 생성
        self.in_layers = []
        for i in range(2 * window_size):
            layer = Embedding(W_in) # Embedding 계층 사용
            self.in_layers.append(layer)
        self.ns_loss = NegativeSamplingLoss(W_out, corpus, power=0.75, sample_size=5)

        # 모든 가중치와 기울기를 배열에 모은다.
        layers = self.in_layers + [self.ns_loss]
        self.params, self.grads = [], []
        for layer in layers:
            self.params += layer.params
            self.grads += layer.grads

        # 인스턴스 변수에 단어의 분산 표현을 저장한다.
        self.word_vecs1 = W_in
        self.word_vecs2 = W_out
```

## - CBOW 모델 개선

### 개선 word2vec 학습

#### 하이퍼파라미터 설정

```
window_size = 5
hidden_size = 100
batch_size = 100
max_epoch = 10

# 데이터 읽기
corpus, word_to_id, id_to_word = ptb.load_data('train')
vocab_size = len(word_to_id)

contexts, target = create_contexts_target(corpus, window_size)
if config.GPU:
    contexts, target = to_gpu(contexts), to_gpu(target)
```

#### 모델 생성

```
model = SkipGram(vocab_size, hidden_size, window_size, corpus)
optimizer = Adam()
trainer = Trainer(model, optimizer)
```

#### 학습 시작

```
# 학습 시작
trainer.fit(contexts, target, max_epoch, batch_size, eval_interval=2000)
trainer.plot()
```

## - CBOW 모델 개선

### CBOW 모델 평가

#### 학습한 단어에 대해 거리가 가장 가까운 단어들을 추출

```
pkl_file = './cbow_params.pkl'
with open(pkl_file, 'rb') as f:
    params = pickle.load(f)
```

```
word_vecs = params['word_vecs']
word_to_id = params['word_to_id']
id_to_word = params['id_to_word']
```

```
# 가장 비슷한(most similar) 단어 뽑기
querys = ['you', 'year', 'car', 'toyota']
for query in querys:
    most_similar(query, word_to_id, id_to_word, word_vecs, top=5)
```

### 출력

```
[query] you
we: 0.6103515625
someone: 0.59130859375
i: 0.55419921875
something: 0.48974609375
anyone: 0.47314453125
```

```
[query] year
month: 0.71875
week: 0.65234375
spring: 0.62744140625
summer: 0.6259765625
decade: 0.603515625
```

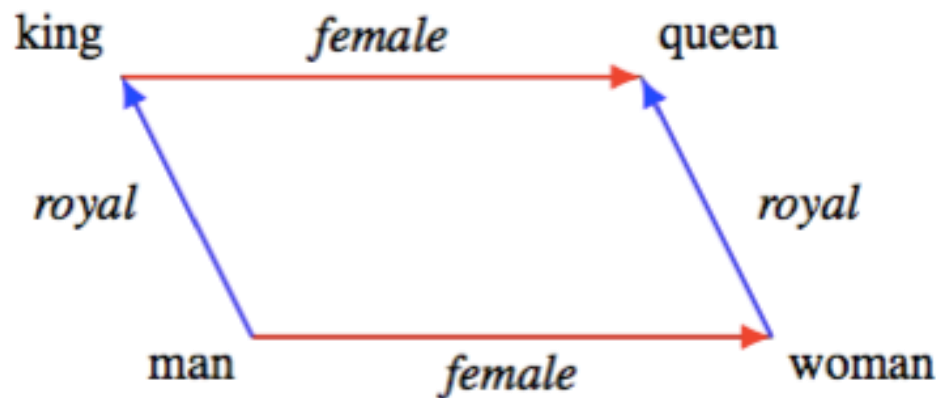
```
[query] car
luxury: 0.497314453125
arabia: 0.47802734375
auto: 0.47119140625
disk-drive: 0.450927734375
travel: 0.4091796875
```

```
[query] toyota
ford: 0.55078125
instrumentation: 0.509765625
mazda: 0.49365234375
bethlehem: 0.47509765625
nissan: 0.474853515625
```

## - CBOW 모델 개선

### CBOW 모델 평가

#### 유추 문제



예)

$$\text{Vec}(\text{woman}) - \text{Vec}(\text{man}) = \text{Vec}(?) - \text{Vec}(\text{King})$$

#### 유추 작업 코드

```
# 유추(analogy) 작업
print('-'*50)
analogy('king', 'man', 'queen', word_to_id, id_to_word, word_vecs)
analogy('take', 'took', 'go', word_to_id, id_to_word, word_vecs)
analogy('car', 'cars', 'child', word_to_id, id_to_word, word_vecs)
analogy('good', 'better', 'bad', word_to_id, id_to_word, word_vecs)
```

```
[analogy] king:man = queen:?
woman: 5.16015625
veto: 4.9296875
ounce: 4.69140625
earthquake: 4.6328125
successor: 4.609375
```

#### 코드

예)

King : man = queen : vec(?)

=> Woman

---

감사합니다

---