파이토치로 배우는
자연어 처리

1장. PyTorch

송선영

CONTENTS

지도 학습이란?

- 샘플에 대응하는 타깃(예측 값)의 정답을 제공하는 방식
- 목적 : 주어진 데이터셋에서 손실 함수를 최소화하는 파라미터 값 고르기 -> 경사 하강법 사용

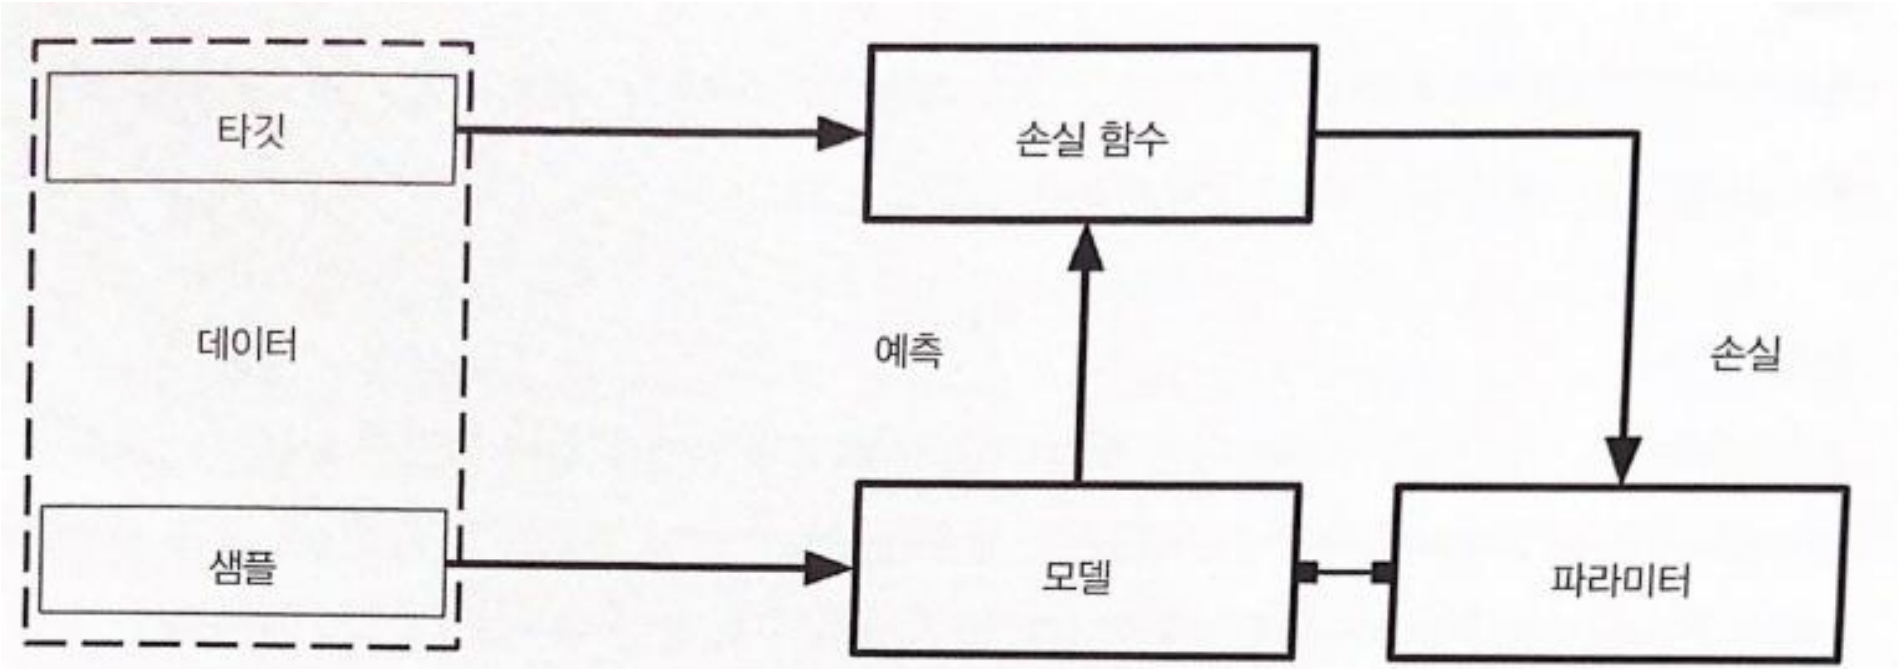

그림 1-1 지도 학습 시스템. 레이블된 입력 데이터에서 시작하는 학습 개념 프레임워크

- 원-핫 표현

Time flies like an arrow.
Fruit flies like a banana.

토큰화 (구두점 무시) →

{ time, fruit, flies, like, a, an, arrow, banana }

	time	fruit	flies	like	a	an	arrow	banana
1_{time}	1	0	0	0	0	0	0	0
1_{fruit}	0	1	0	0	0	0	0	0
1_{flies}	0	0	1	0	0	0	0	0
1_{like}	0	0	0	1	0	0	0	0
1_{a}	0	0	0	0	1	0	0	0
1_{an}	0	0	0	0	0	1	0	0
1_{arrow}	0	0	0	0	0	0	1	0
1_{banana}	0	0	0	0	0	0	0	1

- 'like a banana' 의 원-핫 표현은?

	time	fruit	flies	like	a	an	arrow	banana
1_{like}	0	0	0	1	0	0	0	0
1_{a}	0	0	0	0	1	0	0	0
1_{banana}	0	0	0	0	0	0	0	1

→ 3X8 크기의 행렬,
→ 이진 인코딩은 [0,0,0,1,1,0,0,1]

02 샘플과 타깃의 인코딩

- 원-핫 벡터 또는 이진 표현 만들기

```
from sklearn.feature_extraction.text import CountVectorizer
import seaborn as sns

corpus = ['Time flies like an arrow.',
          'Fruit flies like a banana.']
one_hot_vectorizer = CountVectorizer(binary=True)
one_hot = one_hot_vectorizer.fit_transform(corpus).toarray()
vocab = one_hot_vectorizer.get_feature_names()
sns.heatmap(one_hot, annot=True,
            cbar=False, xticklabels=vocab,
            yticklabels=['Sentence 1', 'Sentence 2'])
```

- TF (Term-Frequency : 문서 빈도)
  - 'Fruit flies like time flies a fruit' 의 TF 표현

time	fruit	flies	like	a	an	arrow	banana
1	2	2	1	1	0	0	0

→ 단어 fruit의 TF : TF(fruit) = 2

- TF-IDF (Term-Frequency-Inverse-Document-Frequency : 문서 빈도 - 역문서 빈도)

$$IDF(w) = \log\frac{N}{n_w} \quad \rightarrow \quad \text{TF-IDF 점수는 TF(w)} * IDF(w)$$

- TF-IDF 표현 만들기

```
from sklearn.feature_extraction.text import TfidfVectorizer
import seaborn as sns

tfidf_vectorizer = TfidfVectorizer()
tfidf = tfidf_vectorizer.fit_transform(corpus).toarray()
sns.heatmap(tfidf, annot=True, cbar=False, xticklabels=vocab,
            yticklabels = ['Sentence 1', 'Sentence 2'])
```

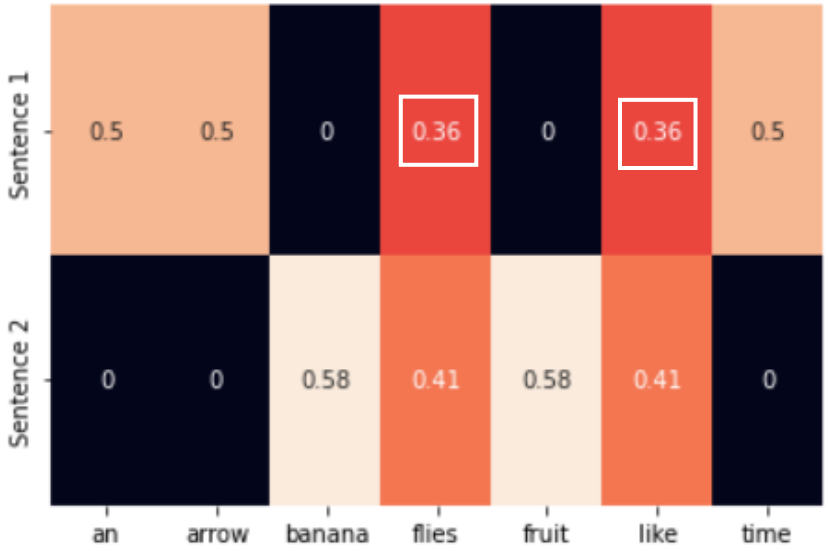

- Sentence 1

```
'Time flies like an arrow.',
'Fruit flies like a banana.'
```

* tfidfVectorizer 에서는 $IDF(w) = \log\left(\frac{N+1}{n_w+1}\right) + 1$ 로 사용

1) flies, like의 TF-IDF 값은?

$$\text{TF} = 1,\ \text{IDF} = \log\left(\frac{2+1}{2+1}\right) + 1 = 1$$

$$\text{TF-IDF} = \text{TF} * \text{IDF} = 1 * 1 = 1$$

2) 단어 an, arrow, time 의 TF-IDF 값은?

$$\text{TF} = 1,\ \text{IDF} = \log\left(\frac{2+1}{1+1}\right) + 1 = 1.405$$

$$\text{TF-IDF} = \text{TF} * \text{IDF} = 1 * 1.405 = 1.405$$

3) flies, like의 L2 Norm 정규화 값은?

$$\frac{1}{\sqrt{2 * 1^2 + 3 * 1.405^2}} = 0.3552$$

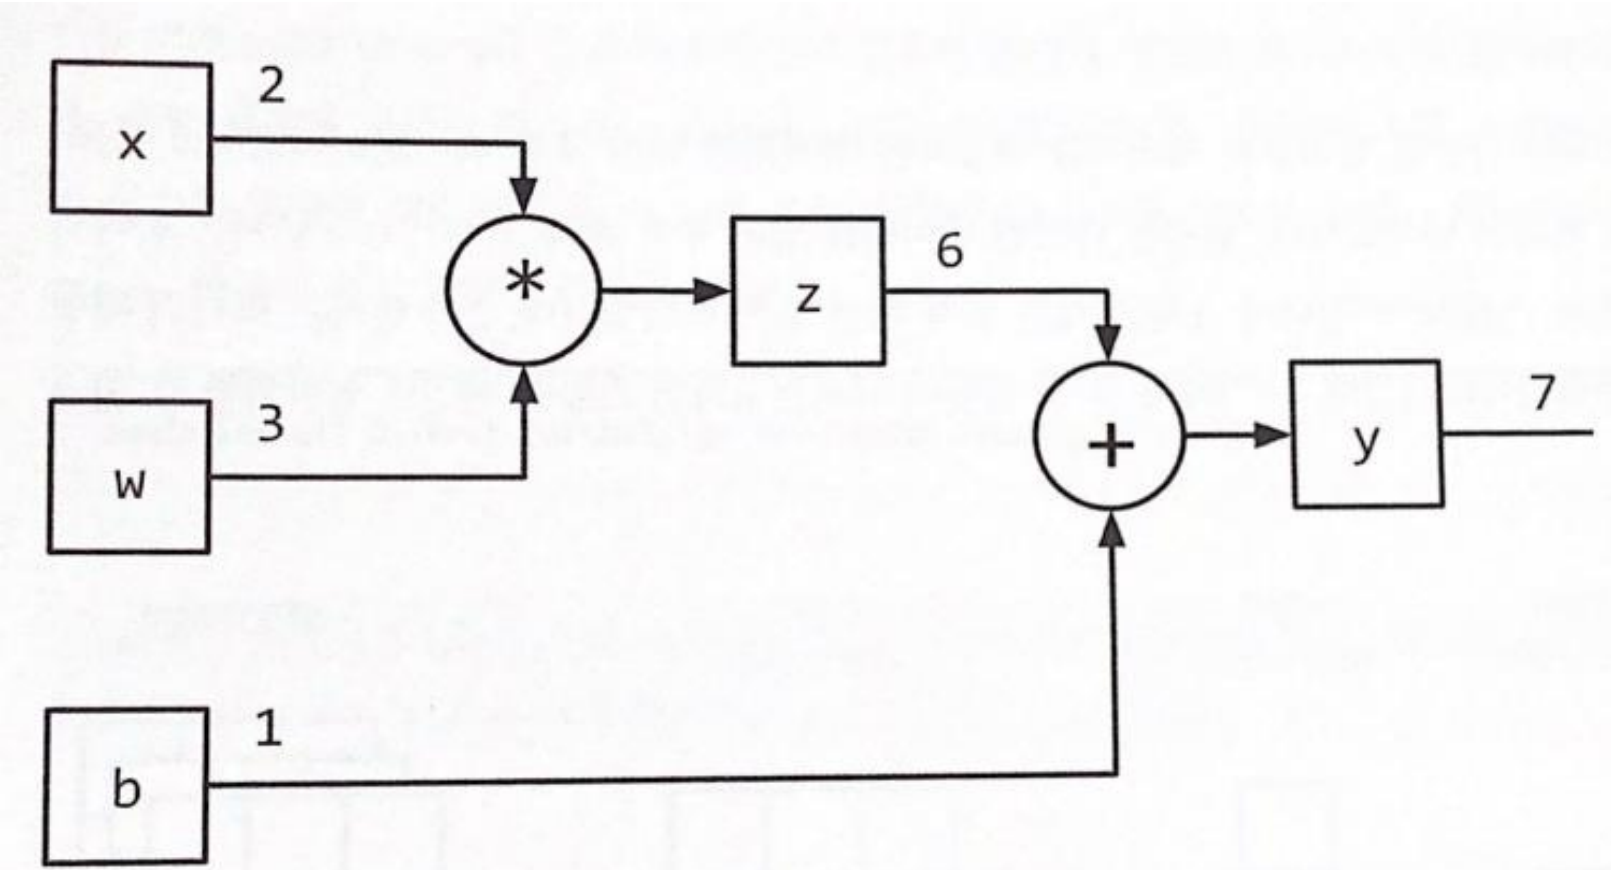

그림 1-6 계산 그래프를 사용한 식 $y = wx + b$의 표현

- 텐서 만들기

```
# 텐서의 속성 출력함수
def describe(x):
  print("타입: {}".format(x.type()))
  print("크기: {}".format(x.shape))
  print("값: ₩n{}".format(x))
```

1)

```
import torch

# 차원을 2X3으로 초기화, 값은 랜덤하게
describe(torch.Tensor(2,3))
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[-3.2454e-33,  3.0684e-41,  1.5695e-43],
        [ 1.5554e-43,  1.5975e-43,  1.6255e-43]])
```

2)

```
describe(torch.rand(2,3)) # [0,1) 범위에서 랜덤하게
describe(torch.randn(2,3)) # 표준 정규 분포값으로 랜덤하게
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[0.6511, 0.6530, 0.9024],
        [0.8751, 0.5086, 0.0415]])
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[-1.4694,  0.1454, -0.1947],
        [ 0.5183, -0.6032, -0.2123]])
```

3)

```
describe(torch.zeros(2,3)) # 0으로 채운 텐서

x = torch.ones(2,3) # 1로 채운 텐서
describe(x)

x.fill_(5) # 5로 채운 텐서
describe(x)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[0., 0., 0.],
        [0., 0., 0.]])
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[1., 1., 1.],
        [1., 1., 1.]])
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[5., 5., 5.],
        [5., 5., 5.]])
```

4)

```
x = torch.Tensor([[1,2,3],
                  [4,5,6]])
describe(x)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[1., 2., 3.],
        [4., 5., 6.]])
```

5)

```
import numpy as np

npy = np.random.rand(2,3)

# numpy로 텐서 만들기
# numpy 배열은 float64 타입이기 때문에 tensor type은 DoubleTensor
describe(torch.from_numpy(npy))
```

```
타입: torch.DoubleTensor
크기: torch.Size([2, 3])
값:
tensor([[0.7036, 0.6288, 0.0352],
        [0.3571, 0.3298, 0.9034]], dtype=torch.float64)
```

- 텐서 타입

1)
```
x = torch.FloatTensor([[1,2,3],
                       [4,5,6]])
describe(x)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[1., 2., 3.],
        [4., 5., 6.]])
```

2)
```
x = torch.LongTensor([[1,2,3],
                      [4,5,6]])
describe(x)
```

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[1, 2, 3],
        [4, 5, 6]])
```

3)
```
x = torch.tensor([[1,2,3],
                  [4,5,6]], dtype=torch.int64)
describe(x)
```

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[1, 2, 3],
        [4, 5, 6]])
```

4)
```
x = x.long()
describe(x)
```

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[1, 2, 3],
        [4, 5, 6]])
```

5)
```
x = x.float()
describe(x)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[1., 2., 3.],
        [4., 5., 6.]])
```

- 텐서 연산

```
x = torch.randn(2,3)
describe(x)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[ 0.3957, -1.3422, -1.7639],
        [ 0.4326, -1.9294,  0.6513]])
```

1)

```
describe(torch.add(x,x))
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[ 0.7914, -2.6844, -3.5277],
        [ 0.8653, -3.8588,  1.3026]])
```

2)

```
describe(x + x)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 3])
값:
tensor([[ 0.7914, -2.6844, -3.5277],
        [ 0.8653, -3.8588,  1.3026]])
```

- 차원별 텐서 연산

```
x = torch.arange(6) # 0~5까지 1씩 증가하는 텐서 생성
describe(x)
```

```
타입: torch.LongTensor
크기: torch.Size([6])
값:
tensor([0, 1, 2, 3, 4, 5])
```

1)

```
# 동일한 데이터를 공유하는 텐서를 2X3 크기로 생성
x = x.view(2,3)
describe(x)
```

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[0, 1, 2],
        [3, 4, 5]])
```

2)

```
describe(torch.sum(x, dim=0)) # 행
```

```
타입: torch.LongTensor
크기: torch.Size([3])
값:
tensor([3, 5, 7])
```

3)

```
describe(torch.sum(x, dim=1)) # 열
```

```
타입: torch.LongTensor
크기: torch.Size([2])
값:
tensor([ 3, 12])
```

4)

```
describe(torch.transpose(x,0,1))
```

```
타입: torch.LongTensor
크기: torch.Size([3, 2])
값:
tensor([[0, 3],
        [1, 4],
        [2, 5]])
```

- 텐서 인덱싱

x :

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[0, 1, 2],
        [3, 4, 5]])
```

1)

```
describe(x[:1, :2])
```

```
타입: torch.LongTensor
크기: torch.Size([1, 2])
값:
tensor([[0, 1]])
```

2)

```
describe(x[0, 1])
```

```
타입: torch.LongTensor
크기: torch.Size([])
값:
1
```

3)

```
indices = torch.LongTensor([0,2])
describe(torch.index_select(x, dim=1, index=indices))
```

```
타입: torch.LongTensor
크기: torch.Size([2, 2])
값:
tensor([[0, 2],
        [3, 5]])
```

→ x[: , [0,2]] 로 표현할 수 있음
(텐서는 배열 인덱싱 가능)

4)

```
indices = torch.LongTensor([0,0])
describe(torch.index_select(x, dim=0, index=indices))
```

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[0, 1, 2],
        [0, 1, 2]])
```

→ x[[0,0], :] 로 표현할 수 있음

5)

```
row_indices = torch.arange(2).long()
col_indices = torch.LongTensor([0,1])
describe(x[row_indices, col_indices])
```

```
타입: torch.LongTensor
크기: torch.Size([2])
값:
tensor([0, 4])
```

- 텐서 연결

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[0, 1, 2],
        [3, 4, 5]])
```

1)
```
describe(torch.cat([x, x], dim=0))
```

```
타입: torch.LongTensor
크기: torch.Size([4, 3])
값:
tensor([[0, 1, 2],
        [3, 4, 5],
        [0, 1, 2],
        [3, 4, 5]])
```

2)
```
describe(torch.cat([x, x], dim=1))
```

```
타입: torch.LongTensor
크기: torch.Size([2, 6])
값:
tensor([[0, 1, 2, 0, 1, 2],
        [3, 4, 5, 3, 4, 5]])
```

3)
```
describe(torch.stack([x, x]))
```

```
타입: torch.LongTensor
크기: torch.Size([2, 2, 3])
값:
tensor([[[0, 1, 2],
         [3, 4, 5]],

        [[0, 1, 2],
         [3, 4, 5]]])
```

- 텐서 선형 대수 계산: 행렬 곱셈

1)

```
x1 = torch.arange(6).view(2, 3)
describe(x1)
```

```
타입: torch.LongTensor
크기: torch.Size([2, 3])
값:
tensor([[0, 1, 2],
        [3, 4, 5]])
```

2)

```
x2 = torch.ones(3, 2)
x2[:, 1] += 1
describe(x2)
```

```
타입: torch.FloatTensor
크기: torch.Size([3, 2])
값:
tensor([[1., 2.],
        [1., 2.],
        [1., 2.]])
```

3)

```
# 행렬 곱
describe(torch.mm(x1, x2))
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 2])
값:
tensor([[ 3.,  6.],
        [12., 24.]])
```

- 그래디언트 연산을 할 수 있는 텐서 만들기

1)

```
# requires_grad=True : gradient기반 학습에 필요한 손실함수와
#                      텐서의 gradient를 기록하는 부가 연산을 활성화시킴
x = torch.ones(2,2,requires_grad=True)
describe(x)
print(x.grad is None)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 2])
값:
tensor([[1., 1.],
        [1., 1.]], requires_grad=True)
True
```

2)

```
y = (x + 2) * (x + 5) + 3
describe(y)
print(x.grad is None)
```

```
타입: torch.FloatTensor
크기: torch.Size([2, 2])
값:
tensor([[21., 21.],
        [21., 21.]], grad_fn=<AddBackward0>)
True
```

3)

```
z = y.mean()
describe(z)
z.backward() # 역방향 계산
print(x.grad is None) # 파라미터 값 업데이트
```

```
타입: torch.FloatTensor
크기: torch.Size([])
값:
21.0
False
```

- CUDA 텐서 만들기

1)
```
import torch

# GPU를 사용할 수 있는지 확인
print(torch.cuda.is_available())
```

```
True
```

2)
```
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print(device)
```

```
cuda
```

3)
```
# .to(device) : 초기화되는 모든 텐서를 device로 이동
x = torch.rand(3,3).to(device)
describe(x)
```

```
타입: torch.cuda.FloatTensor
크기: torch.Size([3, 3])
값:
tensor([[0.2583, 0.7546, 0.5726],
        [0.6367, 0.9254, 0.2455],
        [0.6666, 0.2728, 0.5424]], device='cuda:0')
```

05 연습문제 풀이

1. 2D 텐서를 만들고 차원0 위치에 크기가 1인 차원을 추가하세요.

```
x = torch.rand(3,3)
x.unsqueeze(0) # unsqueeze : 차원 추가
```

```
tensor([[[0.8014, 0.0514, 0.9397],
         [0.9315, 0.2283, 0.2760],
         [0.4364, 0.6279, 0.5328]]])
```

2. 이전 텐서에 추가한 차원을 삭제하세요.

```
x.squeeze(0) # squeeze : 차원 삭제
```

```
tensor([[0.8014, 0.0514, 0.9397],
        [0.9315, 0.2283, 0.2760],
        [0.4364, 0.6279, 0.5328]])
```

3. 범위가 [3,7) 이고 크기가 5X3인 랜덤한 텐서를 만드세요.

```
3 + torch.rand(5,3) * (7 - 3)
```

```
tensor([[6.9068, 4.8757, 4.5152],
        [4.6034, 3.7457, 3.3121],
        [6.3022, 6.9982, 4.1004],
        [3.4428, 3.0758, 3.8916],
        [4.4835, 4.2571, 4.9507]])
```

4. 정규 분포(평균=0, 표준편차=1)를 사용해 텐서를 만드세요.

```
y = torch.rand(3,3)
y.normal_()
```

```
tensor([[ 0.8542, -0.3467,  0.1965],
        [ 0.3784, -1.5019,  0.9928],
        [ 1.4040, -1.5264, -1.1240]])
```

5. 텐서 torch.Tensor([1,1,1,0,1])에서 0이 아닌 원소의 인덱스를 추출하세요.

```
z = torch.Tensor([1,1,1,0,1])
torch.nonzero(z) # 0이 아닌 원소의 인덱스를 각 행에 담은 2차원 텐서 반환
```

```
tensor([[0],
        [1],
        [2],
        [4]])
```

6. 크기가 (3,1)인 랜덤한 텐서를 만들고 네 벌을 복사해 쌓으세요.

```
a = torch.rand(3,1)
a.expand(3,4) # expand : 차원을 지정한 크기로 늘림
```

```
tensor([[0.5165, 0.5165, 0.5165, 0.5165],
        [0.6917, 0.6917, 0.6917, 0.6917],
        [0.6468, 0.6468, 0.6468, 0.6468]])
```

7. 2차원 행렬 두 개 (a=torch.rand(3,4,5), b=torch.rand(3,5,4))의 배치 행렬 곱셈을 계산하세요.

```
a = torch.rand(3,4,5)
b = torch.rand(3,5,4)
torch.bmm(a,b)
```

```
tensor([[[1.0386, 1.4453, 1.7456, 1.3421],
         [0.4723, 0.9527, 0.8589, 0.9381],
         [1.0421, 1.6625, 1.3155, 1.0276],
         [0.9465, 1.5191, 1.2271, 1.1003]],

        [[1.1134, 2.3441, 1.6213, 1.3923],
         [1.1273, 2.0009, 1.0427, 0.9958],
         [1.0874, 2.1094, 1.1745, 1.0444],
         [0.5968, 1.1984, 0.9247, 0.7648]],

        [[1.1146, 1.2656, 0.7895, 1.1093],
         [0.9750, 1.5759, 0.5496, 1.0222],
         [1.2607, 2.2045, 1.2941, 1.6045],
         [1.2394, 1.6743, 0.8356, 1.2604]]])
```

8. 3차원 행렬 (a=torch.rand(3,4,5))과 2차원 행렬 (b=torch.rand(5,4))의 배치 행렬 곱셈을 계산하세요.

```
a = torch.rand(3,4,5)
b = torch.rand(5,4)
torch.bmm(a,b.unsqueeze(0).expand(a.size(0), *b.size()))
```

```
tensor([[[2.1304, 1.9087, 1.4814, 2.4756],
         [1.5502, 1.1930, 1.7015, 1.7419],
         [0.9293, 1.0629, 1.3755, 1.0421],
         [1.7158, 1.6989, 1.4377, 1.8749]],

        [[1.4000, 1.3929, 1.6851, 1.7808],
         [1.6698, 1.4921, 1.8138, 2.0628],
         [1.3281, 0.9839, 1.0700, 1.2057],
         [1.2654, 1.5894, 1.1394, 1.5462]],

        [[1.4998, 1.8576, 1.3409, 1.7861],
         [1.1226, 1.3150, 1.5093, 1.6007],
         [1.8970, 1.6597, 1.6978, 1.8861],
         [1.0390, 1.0869, 0.9939, 1.2537]]])
```

```
torch.matmul(a,b)
```

```
tensor([[[2.1304, 1.9087, 1.4814, 2.4756],
         [1.5502, 1.1930, 1.7015, 1.7419],
         [0.9293, 1.0629, 1.3755, 1.0421],
         [1.7158, 1.6989, 1.4377, 1.8749]],

        [[1.4000, 1.3929, 1.6851, 1.7808],
         [1.6698, 1.4921, 1.8138, 2.0628],
         [1.3281, 0.9839, 1.0700, 1.2057],
         [1.2654, 1.5894, 1.1394, 1.5462]],

        [[1.4998, 1.8576, 1.3409, 1.7861],
         [1.1226, 1.3150, 1.5093, 1.6007],
         [1.8970, 1.6597, 1.6978, 1.8861],
         [1.0390, 1.0869, 0.9939, 1.2537]]])
```

끝